




minLSTM

Were RNNs All We Needed? — Feng et al., arXiv:2410.01201 (2024)

Problemy Klasycznego LSTM

Dwa fundamentalne ograniczenia wynikają z tego samego źródła: bramki zależą od h_{t-1} .

Sekwencyjne BPTT

Każdy krok t wymaga wyniku kroku $t - 1$ — obliczeń nie można zrównoleglić wzdłuż wymiaru czasu. Dla sekwencji długości T : T sekwencyjnych operacji na GPU.

Duża liczba parametrów

$O(4d_h(d_x + d_h))$. Przy $d_h = 2d_x$ to **~12×** więcej niż minimalna liczba potrzebna do zdefiniowania rekurencji.

Klasyczny LSTM — Przypomnienie

Równania bramek

$$f_t = \sigma(\text{Linear}([x_t, h_{t-1}]))$$

$$i_t = \sigma(\text{Linear}([x_t, h_{t-1}]))$$

$$o_t = \sigma(\text{Linear}([x_t, h_{t-1}]))$$

$$\tilde{c}_t = \tanh(\text{Linear}([x_t, h_{t-1}]))$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

$$h_t = o_t \odot \tanh(c_t)$$

Wąskie gardło

Zależność od h_{t-1} we **wszystkich czterech bramkach** uniemożliwia zrównoleglenie — wejścia do algorytmu równoległego nie są znane z góry.

- ❏ To właśnie ta zależność jest źródłem obu problemów: sekwencyjności BPTT i nadmiernej liczby parametrów.

Trzy Kroki Uproszczenia → minLSTM

1

Usunięcie zależności od h_{t-1}

Bramki zależą wyłącznie od x_t .

Wszystkie $f_t, i_t, \tilde{c}_t$ można policzyć **równolegle** przed rekurencją.

2

Usunięcie tanh z kandydata

tanh stabilizował gradienty przy mnożeniu przez h_{t-1} . Po kroku 1 zależność znika — tanh jest zbędny: $\tilde{h}_t = \text{Linear}(x_t)$.

3

Normalizacja bramek

Wymuszenie $f'_t + i'_t = 1$ przez softmax. Stan h_t to ważona średnia — skala nie rośnie z T . Bramka wyjściowa o_t i stan c_t stają się zbędne.

Finalna Postać minLSTM

Równanie rekurencji

$$h_t = f'_t \odot h_{t-1} + i'_t \odot \tilde{h}_t$$

$$f_t = \sigma(\text{Linear}(x_t)), \quad i_t = \sigma(\text{Linear}(x_t))$$

$$f'_t = \frac{f_t}{f_t + i_t}, \quad i'_t = \frac{i_t}{f_t + i_t}$$

Redukcja parametrów

$O(3 d_h d_x)$ zamiast $O(4 d_h (d_x + d_h))$

Przy $d_h = 2d_x$:

~25% parametrów klasycznego LSTM

Usunięto: bramkę wyjściową o_t , stan komórki c_t , tanh oraz połączenia rekurencyjne w bramkach.

Parallel Scan — Równoległość w Praktyce


Liniowa rekurencja pierwszego rzędu

$$h_t = a_t \odot h_{t-1} + b_t$$

gdzie $a_t = f'_t$ i $b_t = i'_t \odot \tilde{h}_t$ zależą **wyłącznie od** x_t — znane z góry dla całej sekwencji.

Algorytm **prefix scan** (Blelloch, 1990): $O(\log T)$ kroków zamiast $O(T)$.

Przyspieszenie (GPU T4, batch=64)



Minimalna Liczba Warstw

Dlaczego to ważne?

Przy **1 warstwie** bramki f'_t, i'_t zależą od x_t — tokeny są stałe, więc bramki są **time-independent**. Model ma ograniczoną zdolność modelowania zależności czasowych.

Przy **2+ warstwach** wyjście $h_{1:T}^{(1)}$ jest time-dependent — bramki w warstwie 2 odzyskują pełną ekspresywność.

 **Wniosek:** minLSTM wymaga minimum 2 warstw dla nietrywialnych zadań.

Podsumowanie

3 zmiany

Usunięcie h_{t-1} z bramek, usunięcie tanh, normalizacja bramek ($f'_t + i'_t = 1$).

25% parametrów

$O(3 d_h d_x)$ vs $O(4 d_h (d_x + d_h))$ — przy $d_h = 2d_x$.

235× szybciej

Parallel scan: $O(\log T)$ zamiast $O(T)$. Dla $T=512$ na GPU T4.

Porównywalna jakość

Wyniki na benchmarkach porównywalne z LSTM, GRU i Mambą.

minLSTM pokazuje, że złożoność LSTM nie była konieczna — prostsza komórka rekurencyjna może być równie skuteczna i wielokrotnie szybsza w uczeniu.